

Reinforcement Learning - Flexible Route Planning

Die Aufgabenstellung

Die Versorgung der Stationen in der Fabrik soll weg von einem starren Routenzug mit starren Zeiten. Die Stationen sollen bei Bedarf automatisch versorgt werden.

Dafür sind klassische Ansätze durchaus gut geeignet. Hier soll zum Erlernen allerdings ein Reinforcement Learning Ansatz gewählt werden.

Ihre Aufgabe ist das Training der AGV- und Lager-Agent*innen, die die Steuerung übernehmen. Über die prinzipielle Funktionsweise werden Sie in der Vorlesung informiert bzw. können sich selbstständig vertieft einlesen. Die Struktur der Agent*innen, die Umgebung sowie das Verhalten des AGV sind teilweise programmiert und vorgegeben, Sie sollen hier Erfahrungen sammeln, wie die Belohnungen verteilt werden können/sollten und was für Schwierigkeiten bzw. unerwünschte Verhaltensweisen daraus resultieren.

Ihre Agent*innen werden dann gegen diejenigen Ihrer Kommiliton*innen antreten und nach einem festen Punkteschema bewertet werden.

Die Fabrik

In der Fabrik werden Taschenlampen gefertigt.

Die Fabrik weist den unten gezeigten Lageplan auf. Es werden ganz kurz die Stationen aufgezeigt und insbesondere, was für Aufträge an diesen zu erfüllen sein könnten.

Die Stationen sind nummeriert und haben verschiedene Aufträge, die zu erfüllen sind. Diese beinhalten: Material bereitstellen oder Material abholen. In diesem Szenario ist es so, dass diese Materialien alle direkt mit dem Lager ausgetauscht werden, ein Liefern zwischen den Stationen ist nicht nötig.

Der Einfachheit halber sind keine Personen oder Flurförderfahrzeuge unterwegs, das AGV kann die Stationen demnach ungehindert erreichen.

Auf der nächsten Seite findet sich der Übersichtsplan sowie eine Tabelle, die die Aufgaben an den Stationen schildert.



Nr.	Art und Aufgabe	Aufgabe für AGV
0	Lager - Waren ausgeben/entgegennehmen	Abholen der Waren für Stationen und Abgeben von Leergut
1	Identisch zu Station 0	Identisch zu Station 0
2	LED auf Platine stecken	Anliefern LEDs
3	Lötstation	Anliefern Lötzinn
4	Einlegen Batterie	Anliefern Batterien
5	Einlegen Platine in Gehäuse	Anliefern Gehäuseteile
6	Verschrauben Gehäuse – Option für Metall- und Kunststoffgehäuse	Anliefern Schrauben
7	Verkleben Gehäuse – Option für Kunststoff- und Holz-Gehäuse	Anliefern Klebstoff
8	Lackiererei – Optionales Lackieren	Anliefern Lackfass und gleichzeitiges Abholen leeres Fass -> 1:1 Tausch
9	Druckerei – Aufdruck auf Taschenlampe	Anliefern Etiketten und Druckertinte
10	Bohrstation – Halterung Taschenlampe Löcher für Befestigung Vorbohren	Anliefern Bohrer
11	Montage Halterung	Anliefern der Halterung
12	Teststation – Überprüfen der Funktionalität der Taschenlampen	Abholen Container mit defekten, aussortierten Taschenlampen

Die wichtigste Information hieraus ist, dass an den Station 2-11 Waren vom AGV abgeliefert wird und an der Station 12 Ware abgeholt wird. Eine Besonderheit stellt noch die Station 8 (Lackiererei) dar, an der ein 1:1-Tausch von Ware stattfindet, d.h. es wird sowohl Ware abgeliefert, als auch Leergut mitgenommen.

Die Auftragsliste

Die Auftragsliste, die vom AGV abgearbeitet werden muss, ergibt sich automatisch aus den Rückmeldungen der Stationen, welche Ware benötigt bzw. abgeholt werden muss. Zudem melden

die Stationen zurück, in welcher Zeit dieser Auftrag erfüllt sein muss, so dass es nicht zu Störungen im Betriebsablauf kommt. Eine typische Auftragsliste sieht dabei wie unten links aus.

```
2 1, t 729
3 3, t 850
4 0, t 0
5 1, t 718
6 0, t 0
7 0, t 0
8 1, t 366
9 2, t 460
10 1, t 873
11 0, t 0
12 1, t 379
```

Hier ist die Auftragsliste tabellarisch dargestellt. Die erste Spalte gibt die Stationsnummer an, die zweite Spalte den Bedarf in Wareneinheiten und die dritte Spalte, die mit einem „t“ beginnt, gibt die Zeit in Sekunden an, die für den Auftrag noch verbleiben. Wird diese Zeit überschritten, gibt es Störungen im Betriebsablauf.

Beispielhaft sagt diese Auftragsliste, dass an der Lötstation (Station 3) gerade 3 Wareneinheiten Lötzinn benötigt werden, und dass noch genügend Lötzinn für 850 Sekunden zur Verfügung steht, bevor es dann zu Störungen im Betriebsablauf kommt.

Der dringlichste Auftrag wäre demnach derjenige der Station 8 (Lackiererei), die frischen Lack benötigt (noch 366 Sekunden).

Die Stationen 0 und 1 (Lager) tauchen in der Auftragsliste nicht auf, da sie selbst keine Aufträge für das AGV haben.

Das AGV

Das AGV ist einer der Agent*innen, die trainiert werden sollen.



Das AGV hat Platz für 4 Wareneinheiten. Seine Geschwindigkeit ist von der Beladung abhängig. Je stärker es beladen ist, desto langsamer ist es. Die Geschwindigkeit sinkt linear mit der Beladung (egal welche Art von Wareneinheit, es trägt) und beträgt bei voller Beladung noch 80% der Maximalgeschwindigkeit (Geschwindigkeit sinkt also um 5%-Punkte je

Wareneinheit). Ist es ganz leer, braucht es 20 Sekunden um sich 1 Kachel fortzubewegen. Zusätzlich braucht das AGV für Kommunikation mit der Station und Warenaustausch ebenfalls 20 Sekunden. Diese 20 Sekunden fallen aber nur 1x an, egal wie viele Wareneinheiten ausgetauscht werden. So kann das AGV beispielsweise am Lager in 20 Sekunden 4 unterschiedliche Wareneinheiten aufnehmen.

Das AGV entscheidet, welche Station als nächstes angefahren wird. Die Route, also wie es fährt, ist fest einprogrammiert. Dies bedeutet, dass der*die Agent*in zwischen 12 Aktionen wählen kann („Fahre zu Station x “ mit $0 \leq x \leq 12$). Für die Entscheidung werden die folgenden Informationen bereitgestellt:

- Welche Waren das AGV geladen hat
- Die Position, an welcher sich das AGV gerade befindet
- Wie viel Leergut an der Teststation abgeholt werden muss (kann auch 0 sein)

Details finden sich weiter hinten.

Das Lager

Im Lager sind alle nötigen Waren zu finden. Die Aufgabe des Lagers ist es zu entscheiden, welche Waren auf das AGV geladen werden. Kommt das AGV also an einem Portal des Lagers an, übernimmt das Lager das Steuer.

Dabei entscheidet das Lager für welche Station aufgeladen wird, die Menge wird *automatisch* an die Auftragsliste angepasst. Zu einer „Unterversorgung“ der Station kann es nur kommen, wenn nicht mehr genügend Platz auf dem AGV ist, um alle Waren aufzuladen. Zusätzlich bestimmt das Lager, wann die Interaktion mit dem AGV endet (es kann einen Befehl zum Abfahren des AGV geben). Somit stehen dem Lager 11 Aktionen zur Verfügung – 10 Aktionen für das Aufladen der entsprechenden Ware (nur 10, da es zwar 13 Stationen gibt, aber für die beiden Lager und die Teststation keine Waren aufgeladen werden müssen) und 1 Aktion, die das Wegfahren des AGV auslöst. Für diese Entscheidung stehen die folgenden Informationen zur Verfügung:

- Von der Auftragsliste, wie viele Waren die Stationen jeweils benötigen
- Wie dringend die Aufträge von den Stationen sind (in Stufen)
- Welche Waren sich bereits auf dem AGV befinden

Details finden sich weiter hinten.

Die Wertung

Das Spiel wird nach den folgenden Kriterien bewertet. Wichtig ist, dass diese Punkte nicht direkt für das Reinforcement Learning verwendet werden können. Damit können die Agent*innen nicht zuverlässig trainiert werden, auch wenn das Ziel natürlich ist, die Punkte zu Maximieren.

Die Wertung erfolgt nach dem Folgenden Schema:

- Für jeden erfolgreich erfüllten Stationsauftrag wird pro Wareneinheit 1 Punkt vergeben
- Für zu spät erfüllte Aufträge gibt es Minuspunkte und zwar so, dass alle 20 Sekunden für jede Station, deren Auftrag nicht rechtzeitig erfüllt wird, 1 Punkt abgezogen wird (genauer erfolgt das Abziehen linear und es wird abgerundet. Das bedeutet aber, dass wenn bei 2 Stationen Aufträge zur selben Zeit jeweils 10 Sekunden in Rückstand sind, gibt es bereits 1 Punkt Minus)

Zu beachten ist noch, dass eine Teilerfüllung von Aufträgen an einer Station dazu führt, dass die Aufträge nicht mehr ganz so dringend sind und die Zeit für die Erfüllung um 300 Sekunden angehoben wird.

Das Training

Prinzipiell ist hier alles erlaubt. Das vorgeschlagene Vorgehen ist folgendermaßen:

1. (Vor-) Training des AGV. Dies kann völlig unabhängig vom Lager erfolgen, es geht hier nur darum, eine möglichst sinnige Reihenfolge des Abfahrens der Stationen, für die Waren aufgeladen wurden, zu gewährleisten. Zudem muss das AGV selbsttätig die Entscheidung treffen, ob ein Anfahren der Teststation sinnvoll ist.
2. (Vor-) Training des Lagers. Hier sollte das Lager davon ausgehen können, dass das AGV sinnvolle Entscheidungen trifft. Das Lager kann also abschätzen, wie lange das AGV für eine sinnvolle Route brauchen sollte. Generell wird vorgeschlagen, erst einen „heuristischen“ Ansatz zu wählen, der Belohnungen verteilt, die sich an der Lage der Stationen (eng beieinanderliegende Stationen beim Beladen bevorzugen), der Kapazität des AGV (möglichst voll beladen, da jede Interaktion mit Stationen 20 Sekunden benötigt) und der Dringlichkeit der Aufträge orientieren.
3. Gemeinsames Training (optional). Hier werden beide Agent*innen gemeinsam trainiert um ggf. Schwächen des anderen kennenzulernen und darauf zu reagieren.

Um ein zu aufwendiges Lernen zu vermeiden, ist bereits eine „Filter-Technik“ implementiert, die den Lernprozess stark beschleunigen soll. Dazu werden folgende Filter verwendet (dürfen auch gerne deaktiviert werden)

- Lager: Es wird verhindert, dass Waren für Stationen aufgeladen werden, die gar keine offenen Aufträge aufweisen
- AGV: Es wird verhindert, dass das AGV Stationen anfährt, für die es keine Waren geladen hat. Ausnahme ist hier natürlich die Teststation (dort werden Waren auf- und nicht abgeladen). Somit wird die Teststation nur dann angefahren, wenn es dort offene Aufträge gibt und das AGV mindestens 1 freien Platz aufweist

Diese Filter verhindern also nur „absolut unsinniges“ Verhalten, erlauben aber natürlich immer noch sehr suboptimale Aktionen (so wird es bspw. selten sinnvoll sein, dass das AGV beladen mit Waren für die Stationen 2 und 3 erst Station 2 anfährt, dort 1 Wareneinheit abgeliefert, und dann weiter zur Teststation fährt, um dort 1 Ware aufzuladen).

Prinzipiell dürfen Belohnung frei verteilt werden, auch hier ist alles erlaubt. Der Begriff *Belohnung* umfasst dabei auch Bestrafung, das wäre einfach eine Belohnung mit negativem Wert. Oftmals wird versucht, nur mit Belohnungen bzw. Bestrafungen zu arbeiten und dies nicht zu mischen, dies ist hier jedoch anders vorgesehen. Der vorgeschlagene Ansatz umfasst zunächst

- Lager
 - Positive Belohnung, wenn auf dem AGV noch genügend Platz um einen Auftrag komplett zu erfüllen (soll verhindern, dass eine Station öfters angefahren werden muss, weil nur eine Teilerfüllung vorliegt)
 - Negative Belohnung, wenn ein Auftrag nur zum Teil erfüllt wird durch die Ladung (doppelt zu oben, das könnte überdacht werden)
 - Negative Belohnung, wenn (viele) Plätze auf dem AGV frei bleiben (leere Plätze heißen mehr Ladevorgänge, öfters fahren und somit insgesamt größere zurückgelegte Strecke). Soll zu frühes Wegschicken des AGV vermeiden
 - Positive Belohnung, wenn Waren für eine Station mit dringendem Bedarf aufgeladen werden (soll verhindern, dass man mit Aufträgen in Verzug gerät)
 - Negative Belohnung für geschätzte Fahrdistanz des AGV (soll eine sinnvolle Routenplanung gewährleisten, um die Gesamtstrecke zu minimieren). Die Fahrdistanz wird im Vortraining geschätzt und könnte im Finetuning vom AGV zurückgemeldet werden
- AGV
 - Negative Belohnung für gefahrene Distanz/verbrauchte Zeit (soll für eine sinnvolle Routenplanung mit minimalen Strecken sorgen)
 - Große negative Belohnung für Anfahren der Teststation ohne ausreichend Platz auf dem AGV für alle abzuholenden Container (Teilerfüllung)
 - Negative Belohnung für das Anfahren des Lagers, wenn noch Güter für Stationen geladen sind (meist ist es sinnvoll alle Waren, die das Lager ans AGV ausgegeben hat, abzuladen bevor das AGV wieder ans Lager zurückkehrt. Andernfalls hat das Lager schon eine wenig sinnvolle Kombination an Waren gewählt, da das AGV mit unnötigen Waren ja langsamer fährt)
 - Keine Belohnung (0) für das Zurückbringen von Leergut ans Lager (tendenziell zwar eine sinnige Aktion, die meist aber weder zu belohnen noch zu bestrafen ist. AGV sollte tendenziell keine anderen Waren haben, wenn es ans Lager zurückkehrt, also nur wenn es leer ist)

- Keine Belohnung für das Anfahren der Teststation (das wäre zu überdenken; man könnte eine positive Belohnung für das Anfahren geben, wenn es einen dringenden Auftrag dort gibt. Die Idee ist aber, dass das AGV zur Teststation fährt, wenn es eh schon in der Nähe ist und das Lager sollte die Waren so beladen, dass dringende Aufträge der Teststation somit automatisch abgehandelt werden)

Der Einsatz

Die Lager- und AGV-Agent*innen werden gespeichert (die entsprechenden Neuronalen Netze). Es empfiehlt sich eine Versionierung, so dass immer auf einen alten Stand zurückgegriffen werden kann, da es beim Training vorkommen kann, dass man sich in eine ungünstige „Sackgasse“ lernt, von der man schwer wieder rauskommt.

Was wirklich gespeichert wird sind die Gewichtungsfaktoren des Neuronalen Netzes. Diese beiden Dateien werden für den endgültigen Einsatz dann abgegeben und dienen dem Ausspielen des „Factory-Cups“.

Das Organisatorische

Wird in der Vorlesung genannt bzw. kann erfragt werden. Das Wichtigste in Kürze:

- Training AGV
- Training Lager
- Abgeben der Agent*innen nach folgender Nomenklatur: „Team_[X]_[ART].keras“, wobei das „X“ den Teambuchstaben bezeichnet und für „ART“ dann „AGV“ oder „LAGER“ einzutragen ist

Die Details

Können erfragt werden. Hier vielleicht die interessantesten:

- Die Zustände für AGV und Lager sind größtenteils im OHE-Stil gehalten. Dies bedeutet bspw., dass der Standort des AGV für dessen Agent*in als Vektor mit 13 Einträgen angelegt ist. Die Station, an der sich das AGV gerade befindet, hat eine 1 als Eintrag, die anderen sind 0.
- Die Dringlichkeit der Aufträge ist in Intervalle eingeteilt:
 - Sehr dringend (rot): $\Delta t \leq 320$ s
 - Dringend (orange): $\Delta t \leq 640$ s
 - Nicht dringend, aber Vorwarnstufe (gelb): $\Delta t \leq 960$ s
- Das Visualisierungsmodul wird für das Training eigentlich gar nicht benötigt. Es kann aber interessant sein, den Trainingserfolg „visuell“ zu überprüfen und sich nicht nur auf die Ausgabe der Zeit und der Belohnungen zu verlassen.
- Bei den Spielen gewinnt das Team, welches die höhere Punktzahl aufweist – bei Gleichstand entscheidet, wer die Auftragsliste schneller abgearbeitet hat. Für die Spiele wird mit vorgefertigten Szenarien (Auftragslisten) gearbeitet, um eine faire Vergleichbarkeit zu gewährleisten.
- Der Modus der Spiele wird in der Vorlesung bekannt gegeben. Üblicherweise wird in Gruppen gespielt, gefolgt von Halbfinale und Finale.

Die technischen Details

Nach Download von Moodle der gezippten Files werden diese von Ihnen lokal gespeichert (am besten wird die Verzeichnisstruktur beibehalten). Sie können die Datei „requirements.txt“ dann nutzen, um alle nötigen Bibliotheken zu laden.

Das Training erfolgt über das Anpassen der REWARDS in den Dateien

„game_mechanics_4_storage_training.py“ und „game_mechanics_4_agv_training.py“. Exemplarisch sehen Sie hier den entsprechenden Ausschnitt aus der Datei fürs AGV-Training. Schauen Sie sich den Code an und überprüfen, ob Ihre Interpretation nach der Benennung, wie die Rewards zu verstehen sind, auch zutrifft (ich habe aber zumindest versucht, Sie nicht absichtlich in die Irre zu führen).

```
#####  
##### Rewards for agv training #####  
##### Please change as you please #####  
#####
```

```
REWARD_TIME_ELAPSED = 0  
REWARD_NOT_FITTING_STATION = 0  
REWARD_TEST_STATION_NOT_ENOUGH_agv_CAP = 0  
REWARD_EMPTY_BOXES_RETURN = 0  
REWARD_RETURN_TO_STORAGE_WITH_GOODS = 0  
REWARD_RETURN_TO_STORAGE_EMPTY = 0  
REWARD_AGV_GOOD_0 = 0  
REWARD_IMPOSSIBLE_ACTION = 0  
REWARD_UNLOAD_GOOD = 0
```

Gehen Sie mit den Rewards sparsam um, Sie sollten tendenziell Werte zwischen 0 und 1 wählen, Ausnahmen stellen Rewards für absolut unsinnige oder gar unmögliche Aktionen dar – diese dürfen sehr hohe Werte annehmen.

Scheuen Sie sich nicht, mich per Mail zu kontaktieren oder in der Vorlesung anzusprechen, falls Sie auf grundlegende Schwierigkeiten stoßen sollten.